

第 01 章 | 從資料中學習的機器：機器學習基石與視野

學生版公開講義 | 請搭配本課程 Colab，依照段落逐步操作與自我檢查。

來源說明：課程參考《Python Machine Learning, 3rd Edition》；原始範例程式碼採 MIT License。本檔由恩恩統計家教整理為學生版學習摘要，不含原書 PDF 或掃描內容。

1. 本章學習路線

導言與學習重點本章先建立機器學習的基本觀念與資料思維，讓你能在後續章節判斷問題類型、資料形式與合適的學習流程。機器學習 (Machine Learning, ML) 已從人工智慧 (AI) 的一個學術分支，演進為驅動現代科技的實務核心。

機器學習已應用於垃圾郵件過濾、影像分類與蛋白質結構預測等任務，可從資料中找出能支援預測或決策的規律。本章會協助你將資料轉化為學習藍圖，確保你在後續深入演算法細節時，始終保有清晰的導航圖，不至於在細節中迷失。

掌握了大觀念的實務價值後，我們將定義具體的學習目標，作為衡量你掌握程度的基準。

2. 學習目標與核心觀念白話導引

導言與學習重點設定具體學習目標能幫助你追蹤學習進度。對學習者而言，這是一份檢核表，確保學習節奏符合邏輯，從直覺過渡到專業。

學習目標列表

辨識機器學習的三大分支：監督式、非監督式與強化學習的區別。

掌握開發管線 (Roadmap)：理解從前處理到模型部署的標準流程。

使用數學表示法：正確使用特徵矩陣 X 與目標向量 y 的符號規範。

觀念白話導引

監督式學習 (Supervised Learning) —— 「帶解答的考古題」：提供標籤資料 (Labeled data) 與直接回饋，讓機器學習如何預測未來。

非監督式學習 (Unsupervised Learning) —— 「物以類聚的探索題」：在無標籤 (No labels) 且無回饋的情況下，尋找資料中隱藏的結構。

強化學習 (Reinforcement Learning) —— 「訓練寵物的獎懲機制」：透過代理人 (Agent) 與環境互動，利用獎勵機制 (Reward system) 學習一連串的行動決策，如同訓練電腦下西洋棋。

以下整理本章常用術語，方便你閱讀後續內容。

3. 重要術語中英對照與說明

導言與學習重點機器學習是跨學科領域，術語統一至關重要。同一概念在統計學與電腦科學中常有不同稱呼 (如 Sample vs. Instance)，消除這種混淆感是建立「資料思維」的基礎。

重要術語對照表

中文術語	英文術語 / 同義詞	關鍵定義
樣本	Sample / Instance / Observation / Record	資料集中的一橫列。註：在統計文獻中，Sample 有時指代整個資料樣本集。
特徵	Feature / x / Predictor / Attribute / Covariate	資料集中的直行，用於預測的自變數。
目標 / 標籤	Target / y / Label / Dependent variable / Ground truth	想要預測的答案，即響應變數。
分類	Classification	預測離散且無序的類別標籤（如：垃圾郵件辨識）。
回歸	Regression	預測連續性的數值結果（如：房價預測）。
分群	Clustering	探索式分析，將相似特徵的樣本聚集為子群體（Subgroups）。
降維	Dimensionality Reduction	壓縮資料維度，去除雜訊（Noise）並保留關鍵資訊。
泛化能力	Generalization	模型對未見過的新資料做出準確預測的能力。

實際意義：損失函數 (Loss) vs. 成本函數 (Cost) 在模型最佳化中，損失函數衡量的是「單一資料點」的誤差；而成本函數則是整個資料集上所有損失的平均或總和。區分兩者對梯度下降等最佳化演算法至關重要，因為我們最終調教的是整體的代價。

歷史筆記：為何叫「回歸」？「回歸」一詞由 Francis Galton 於 1886 年在其遺傳研究中提出。他觀察到高個子父母的後代，身高往往不會更極端，而是會「回歸」（Regression）到人口的平均身高。這在今日演變為預測連續數值的技術代名詞。

下一節說明特徵矩陣與目標向量的表示方式。

4. 資料的數學表示法：特徵矩陣與向量

導言與學習重點將現實事物抽象化為矩陣，是為了實現電腦的高效批次運算（Vectorized operations）。這不僅是數學需求，更是現代機器學習效能的基石。

資料解剖導讀：以鳶尾花 (Iris Dataset) 為例

結構：150 筆樣本，4 個特徵。

特徵矩陣 X ：寫作 $X \in \mathbb{R}^{150 \times 4}$ ，代表一個 150×4 的二維陣列。

目標向量 y ：寫作 $y \in \{\text{Setosa}, \text{Versicolor}, \text{Virginica}\}_{150}$ 。

數學符號規範

大寫粗體 X ：代表矩陣（Matrix）。

小寫粗體 $x(i)$ ：代表第 i 個樣本（列向量）。

下標 j ：代表特徵維度。

範例： $x_1(150)$ 代表第 150 筆樣本的第一個特徵（例如：花萼長度）。

接著整理從資料前處理到模型評估的標準流程。

5. 機器學習開發管線 (Roadmap)

導言與學習重點模型訓練並非唯一重點。根據 David Wolpert 的「天下沒有白吃的午餐」(No Free Lunch) 定理，沒有任何一個演算法能完美解決所有問題。因此，嚴謹的前處理與評估階段對模型成敗具有決定性影響。

開發流程解析

步驟一：前處理 (Preprocessing)：包含特徵縮放 (Scaling) 與降維。若特徵單位不一（如公分 vs. 公斤），會嚴重拖慢收斂速度。

步驟二：學習 (Learning)：在此階段進行模型選擇。基於「沒有最優演算法」的哲學，我們通常會比較多種模型並調校超參數 (Hyperparameters)。

步驟三：評估 (Evaluation)：必須切分訓練集 (Training Set) 與測試集 (Test Set)。不得在開發過程中使用測試集調整模型，否則會導致對泛化能力的過度樂觀。

步驟四：預測 (Prediction)：將最終模型部署於全新資料。

接著使用 Python 生態系的常用套件完成這些步驟。

6. 工具鏈與 Colab 操作指南

導言與學習重點Python 透過 NumPy 與 SciPy 等套件，封裝了底層的 C 與 Fortran 運算，提供高效率的向量化操作。以下列出範例使用的套件版本。

環境需求表 (Environment Requirements)

套件	版本	實務角色
NumPy	1.17.4	多維陣列與底層數學運算
SciPy	1.3.1	科學計算與矩陣最佳化
pandas	0.25.3	表格化資料操作與整理
Matplotlib	3.1.0	資料視覺化與趨勢觀察
scikit-learn	0.22.0	機器學習演算法核心套件

Colab 操作指南

環境登入：直接使用網頁版 Colab，避開本機安裝路徑報錯。

套件更新：使用 `pip install SomePackage --upgrade` 進行更新。

相容性檢查：由於 Colab 自動更新，出現 Warning 通常可忽略，但若出現 `model.fit(X,y)` 參數報錯，需核對版本。

最後整理常見錯誤與自我檢查方式。

7. 常見錯誤排除與學習自我檢查

導言與學習重點機器學習專案的成敗常在細節。建立預警機制不僅是除錯，更是對模型品質的控管。

常見錯誤分析

錯誤一：Garbage in, garbage out。忽視前處理（如未作特徵縮放）會導致模型失效。

錯誤二：過度擬合訓練集。在學習階段死背資料，導致泛化能力低落。

錯誤三：維度誤判。隨時檢查 `X.shape`（樣本 × 特徵）與 `y.shape` 是否對齊。

動手練習與自我檢查表 (Defensive Checklist)

- [] 場景辨識：預測明天的氣溫是「回歸」還是「分類」？
- [] 術語對齊：你能解釋 Covariate 與 Feature 其實是同一件事嗎？
- [] 數學定義：在符號 $x_2(10)$ 中，上標與下標分別代表什麼意義？
- [] 評估原則：為什麼我們不應使用測試集（Test Set）來調整模型的超參數？
- [] 延伸思考：David Wolpert 的「沒有白吃的午餐」對你選擇演算法有何啟發？

本章總結本章建立了機器學習的基本架構。演算法是工具，模型結果仍取決於資料品質、問題定義與評估流程。下一章將實作感知器與梯度下降。