

第 10 章 | 迴歸分析：從理論到實作

學生版公開講義 | 請搭配本課程 Colab，依照段落逐步操作與自我檢查。

來源說明：課程參考《Python Machine Learning, 3rd Edition》；原始範例程式碼採 MIT License。本檔由恩恩統計家教整理為學生版學習摘要，不含原書 PDF 或掃描內容。

1. 學習概覽：本章學習路線與學習地圖

在機器學習的學習地圖中，如果說「分類」是教電腦做選擇題（如：判斷蘋果或橘子），那麼「迴歸分析」就是教電腦做「填空題」，預測連續性的數值。本章節是你從基礎標籤預測通往商業實務應用（如房價預估、銷售預測、產能估算）的關鍵橋樑。在實作中，我們不只要追求預測精準度，更要追求模型的「穩健性」與「可解釋性」。

學習目標

掌握 EDA 技術：學會使用相關係數熱力圖從眾多特徵中篩選出「資料關係較明顯的特徵」。

理解 OLS 原理：掌握普通最小平方方法（Ordinary Least Squares）的數學本質，理解其如何最小化誤差平方和。

應用 RANSAC 模型：學會透過迭代共識演算法應對現實資料中的離群值（Outliers）。

診斷殘差分佈：透過殘差圖（Residual Plot）進行模型健康檢查，判斷模型是否捕捉了所有規律。

處理非線性關係：演進至多項式迴歸、對數轉換與樹狀模型，並引入正規化（Regularization）防止過擬合。

重要術語對照表

中文術語	英文術語	核心定義與公式
殘差圖	Residual Plot	以預測值為 X 軸，誤差為 Y 軸，診斷模型是否漏掉資訊的圖表。
決定係數	R2 Score	代表模型捕捉到資料變異的百分比。公式： $R^2=1-SST/SSE$ 。
普通最小平方方法	OLS	透過最小化垂直誤差平方和（SSE）來尋找最佳擬合線的方法。
離群值	Outliers	資料集中的極端異常值，容易將線性模型「拉歪」。
隨機樣本共識	RANSAC	迭代演算法，透過隨機選取最小子集來過濾離群值，建立穩健模型。
均方誤差	MSE	預測值與真實值誤差平方的平均數。公式： $MSE=n^{-1}\sum (y-y^{\wedge})^2$ 。

在寫下第一行 `model.fit()` 之前，我們必須先看清資料的真面目。如果餵入的是未經篩選的雜訊，預測結果將毫無商業價值。因此，「觀察資料」是決定模型成敗的實務第一步。

2. 探索性資料分析 (EDA)：找出資料關係較明顯的特徵

核心觀念：資料集的「選美與篩選」

面對擁有多個特徵的資料集（如波士頓房價資料有 13 個特徵），我們不可能漫無目的地嘗試。相關係數 (Pearson's r) 就像是篩選關鍵的濾網，量化特徵與目標變數間的線性相依性（介於 -1 到 1）。

熱力圖 (Heatmap) 導讀

透過 `mlxtend` 產生的熱力圖，請觀察目標變數 `MEDV`（房價中心值）的列：

`RM` (房間數) = 0.70：呈現強烈的正相關。房間越多，房價越高，符合直覺。

`LSTAT` (低收入戶比例) = -0.74：雖然是負數，但絕對值極高。

學習小撇步：負相關的常見誤區

觀念提醒：你可能會誤以為 -0.74 的關係比 0.50 弱。判讀時請記得：相關性強度取決於「絕對值」。-0.74 代表極強的「反向關係」（低收入戶比例越高，房價越低），這種特徵在預測上的貢獻度往往遠高於弱正相關特徵。

確定了資料關係較明顯的特徵後，接著使用線性迴歸估計特徵與目標值之間的線性關係。

3. 線性迴歸基礎與 RANSAC 穩健模型

線性迴歸的直覺：OLS

線性迴歸目標是找出 $y^{\wedge}=w_0+w_1x$ ，最小化真實點到直線的「垂直位移 (Vertical Offsets)」。

數學警告：OLS 假設權重 (w) 與目標之間是線性組合，但不代表特徵本身不能是非線性的。

缺點：OLS 極度畏懼離群值。一個極端的豪宅點會為了縮小其巨大誤差，強行將整條預測線「拉歪」。

RANSAC 演算法：共識的力量

當資料存在「搗蛋鬼」時，我們使用 RANSAC 迭代邏輯：

隨機取樣：隨機挑選「最小數量樣本」（如 50 個點）進行初步擬合，這能將包含離群值的機率降至最低。

設定容忍閾值 (`residual_threshold`)：判定其餘點是否落在這條線的合理誤差範圍內。

判定 Inliers (內點)：符合範圍的點標記為內點，其餘為離群值。

重新訓練與迭代：重複上述過程，最終只拿規模最大的內點集合訓練出模型。

程式碼流程導讀

```
# RANSAC 穩健迴歸：設定關鍵參數 residual_threshold
from sklearn.linear_model import LinearRegression, RANSACRegressor

# 核心邏輯：LinearRegression 作為基礎估計器，RANSAC 負責篩選離群值
ransac = RANSACRegressor(LinearRegression(),
                           max_trials=100,
                           min_samples=50,
                           residual_threshold=5.0,
                           random_state=0)

ransac.fit(X, y)
```

模型訓練完後，別急著看分數。我們必須進行「健康檢查」，看看模型是否遺漏了重要的資料模式。

4. 模型健康檢查：殘差圖與評估指標

殘差圖 (Residual Plot) 診斷

殘差分佈：理想情況下，殘差應在 0 線上下隨機分布，且不呈現明顯結構；若出現曲線或漏斗形狀，表示模型可能遺漏非線性或變異數不等的關係。

微笑曲線警訊：若殘差呈現 U 型，代表資料存在「非線性趨勢」，直線模型已不足以支應。

評估指標「成績單」

MSE：反映絕對誤差，受資料尺度影響。

R2：標準化分數。 $R^2 = 1 - (SSE/SST)$ 。當 $R^2 = 1$ 代表完美擬合；當 $R^2 = 0$ 代表模型表現與使用平均值作為基準預測相近。

陷阱警告：若測試集 R^2 出現負數，代表模型崩潰，表現甚至比猜平均值還差。這通常源於嚴重的過擬合或資料分佈劇烈變動。

當直線模型無法解釋曲線趨勢時，我們有兩條路：讓直線「轉彎」，或是換成「階梯狀」的預測。

5. 非線性迴歸：進階技術與正規化

讓模型轉彎：多項式與對數轉換

多項式迴歸：透過 `PolynomialFeatures` 創造 x^2, x^3 等平方項。

實作延伸 (Log-Transform)：根據來源實驗，針對 LSTAT 特徵進行對數轉換 ($\log(LSTAT)$) 並對目標 MEDV 開平方根 ($\sqrt{MEDV}$)，能將複雜的曲線拉直，實測可達成 $R^2 = 0.69$ 。這比直接增加多項式次方更容易控制模型複雜度。

樹狀模型：下樓梯預測

隨機森林迴歸：結合多棵決策樹，將 X 軸切成區間，以區間平均值作為預測，形成「階梯狀」預測線。其優點是不需特徵標準化，且對離群值具備天然的抗性。

正規化：複雜度的剎車

當模型變複雜（如高次多項式）時，必須引入正規化：

LASSO (L1)：會將不重要的特徵係數壓縮至零，可用於「特徵選擇」。

Ridge (L2)：防止係數過大，讓模型更平滑。

Elastic Net：結合 L1 與 L2 的優點。

6. Colab 實作攻略：避坑指南與倫理觀點

倫理教材：消失的 Boston 資料集

關鍵背景：`scikit-learn` 已移除 Boston 資料集。原因是其中包含 **B** 欄位（基於非裔美國人比例的統計公式），具有嚴重的種族偏見與倫理爭議。

解決方案：請從指定的 GitHub raw link 下載 `housing.data.txt`。

三大常見錯誤排除 (Troubleshooting)

輸入形狀要求：處理單一特徵時，Scikit-learn 要求輸入為二維。務必使用 `X[:, np.newaxis]`。

資料洩漏 (Data Leakage)：在執行 `StandardScaler` 時，務必「只在訓練集 fit」，然後對測試集進行 transform。先全體 fit 再拆分會導致測試資訊洩漏至訓練過程。

繪圖混亂：畫樹狀預測線前，若不先用 `argsort()` 對 X 軸排序，繪出的線會呈現混亂的「蜘蛛網狀」。

7. 動手練習與自我檢查表

實作挑戰題

轉換賽道：嘗試對 `LSTAT` 進行對數轉換，對比原始特徵與轉換後的 R^2 表現。

正規化實驗：使用 `PolynomialFeatures(degree=10)`，觀察加上 `Lasso(alpha=1.0)` 前後係數的變化。

課後自我檢查表

- ☐ 我能解釋為什麼 RANSAC 初始選取「最小樣本數」是為了規避離群值嗎？
- ☐ 我知道 R^2 公式中的 SSE 與 SST 分別代表什麼嗎？
- ☐ 我是否了解 Boston 資料集中 **B** 欄位的爭議及其對資料科學倫理的意義？
- ☐ 我能畫出殘差圖並解釋「雪花雜訊」與「規律圖形」的差異嗎？
- ☐ 在標準化過程中，我是否確保了 `fit` 只發生在訓練集？

結語：迴歸分析的核心在於「解釋誤差」。一個 R^2 高達 0.9 的模型若殘差圖有明顯微笑曲線，依然是一個失敗的過擬合模型。請多觀察圖表視覺直覺，而非僅僅執著於分數的高低。