

第 11 章 | 非監督式學習：聚類分析

學生版公開講義 | 請搭配本課程 Colab，依照段落逐步操作與自我檢查。

來源說明：課程參考《Python Machine Learning, 3rd Edition》；原始範例程式碼採 MIT License。本檔由恩恩統計家教整理為學生版學習摘要，不含原書 PDF 或掃描內容。

1. 本章學習路線

前面的監督式學習使用已知標籤訓練模型；本章改處理沒有標籤的資料。你將使用聚類方法找出客戶消費紀錄中的群組結構，並比較不同分群結果。

本章由監督式學習轉向非監督式學習（Unsupervised Learning）。聚類分析（Clustering）會依特徵相似度將資料分組，可用於客戶分群、文章主題探索與推薦系統前處理。

接下來，我們將學習如何從無序的資料點中，提煉出具備商業價值的結構化資訊。

2. 學習目標 (Learning Objectives)

完成本章後，你將具備以下四大核心能力：

辨析學習範式：能準確區分監督式學習（有標籤）與非監督式學習（無標籤）的本質差異及其適用場景。

掌握核心演算法：深刻理解 K-means（原型分群）、階層式分群（樹狀結構）與 DBSCAN（密度分群）的運作原理。

模型品質評估：學會運用手肘法（Elbow Method）與輪廓分析（Silhouette Analysis）等內在指標，科學地評估分群效果。

解決幾何結構問題：能辨識資料的幾何特性（如球形或非球形），並選擇正確的工具解決非球形分佈與雜訊（Noise）問題。

3. 核心觀念白話理解

K-means 可拆成以下反覆執行的步驟：

A. K-means：隨機選組長，鄰近找組員

K-means 就像是開學第一天的分組遊戲，其核心是最小化「群內誤差平方和 (SSE)」：

$$SSE = \sum_{j=1}^k \sum_{i=1}^n w(i,j) \|x(i) - \mu(j)\|^2$$

選組長：隨機指定 k 個人當「質心 (Centroid)」。

指派群集：計算每筆資料與各群集中心的歐幾里得距離，指派給最近的中心。

換組長：每一組成員到齊後，取所有成員特徵的平均值，選出「新組長」。

重複更新：反覆執行指派與更新，直到群集結果收斂。

技術洞察：K-means 假設群集是「球形 (Spherical)」的。如果資料長得像半月型，它會分得很痛苦。

B. 階層式分群 (Hierarchical Clustering)：尋找家族血緣

這是一個從小族群不斷合併到大族群的「凝聚式 (Agglomerative)」過程：

合併邏輯：一開始每個人都是獨立族群，接著讓「最相似」的兩個族群合併。

技術細節 (Linkage)：

完整連結 (Complete Linkage)：比較兩個族群中「最不相似（距離最遠）」的成員，以此作為合併依據。這種方法較為穩健。

單一連結 (Single Linkage)：則是比較「最相似（距離最近）」的成員。

樹狀圖 (Dendrogram)：這像是一張「族譜」，呈現了親疏遠近。你可以決定在哪裡「砍一刀」，來決定最終的分群數量。

C. DBSCAN：鄰里的人口密度

這不再是看中心點，而是看「人擠不擠」。

核心點 (Core Point)：「風雲人物」。在半徑 epsilon 內，住著超過 MinPts 個朋友。

邊界點 (Border Point)：「跟班朋友」。朋友不夠多，但至少住在風雲人物的半徑範圍內。

噪音點 (Noise Point)：「邊緣邊緣人」。附近沒鄰居，也不是風雲人物的朋友。

優勢：它能識別任何奇形怪狀的分佈（如半月型），且能自動識別並剔除雜訊。

4. 重要術語中英對照表

英文術語	中文對照	定義簡述
Unsupervised Learning	非監督式學習	在沒有標籤的情況下尋找資料模式。
Prototype-based clustering	原型分群	每個群集由一個中心代表（如 K-means）。
Centroid	質心 / 中心點	群集中所有樣本特徵的平均位置。
Inertia (Within-cluster SSE)	慣性 / 群內誤差平方和	衡量點與其質心的緊密程度，Scikit-learn 中稱為 inertia_。
Elbow Method	手肘法	觀察 SSE 下降速度的轉折點以決定最佳 k 值。
Silhouette Coefficient	輪廓係數	衡量樣本與同群的相似度 vs 他群的差異度 (-1 ~ 1)。
Agglomerative Clustering	凝聚階層分群	「由下而上」逐步合併樣本的分群法。
Dendrogram	樹狀圖	呈現階層分群合併過程的視覺化工具。
Core Point	核心點	在指定半徑 (epsilon) 內擁有足夠鄰居點的樣本。
Curse of Dimensionality	維度災難	在高維空間下，歐幾里得距離會失效，點與點距離都差不多。

5. 程式碼流程導讀：Scikit-learn 實作重點

在寫程式時，請想像你正在引導機器進行一場科學實驗：

為什麼一定要做「特徵縮放 (Feature Scaling)」？這是初學者最容易忘記的。想像資料中有「年薪 (0 - 1,000,000)」與「年齡 (20 - 60)」。如果你不做縮放，年薪上 \$100 的微小差異，在數學距離上會遠大於年齡 1 歲的差異，導致年齡特徵完全被「淹沒」。因此，使用歐幾里得距離前，請先經過 [StandardScaler](#)。

KMeans 的參數小技巧：

`n_clusters`: 決定要分幾組。

`init='k-means++'`: 這是「聰明種子」法，讓初始質心盡量拉開距離，避免模型分得太爛。

`n_init`: 這就像是在擲骰子。因為 K-means 結果受初始位置影響很大，我們會執行 10 次，挑選 SSE 最低的那次作為最終答案，避免運氣不好抽到爛初始點。

DBSCAN 的兩難設定：

`eps` (半徑)：這是對「鄰居」的定義。設得太小會增加噪音點；設得太大則可能合併原本不同的群集。

6. Google Colab 實戰操作步驟

環境與資料準備：使用 `make_blobs` 產生實驗用的球型資料，或用 `make_moons` 產生半月型資料來考驗演算法。

模型訓練與預測：呼叫 `fit_predict(X)`。記住，非監督式學習不需要傳入 `y` (標籤)。

視覺化檢查：繪製散佈圖時，針對 K-means，務必用紅星標註 `cluster_centers_`，這能讓分群邏輯一目了然。

模型體檢 (重點!)：

手肘圖：注意！手肘點不是下降最快的地方，而是「改善速率明顯趨於平緩」的那個轉折處。

輪廓圖：使用 `silhouette_samples` 繪製。好的分群在圖中應該呈現「厚度均勻」且「長度相近」。如果出現極薄的「小刀片」形狀，代表該群集可能包含許多離群值或分類不當。

輪廓係數公式： $s(i)=\max\{b(i),a(i)\}b(i)-a(i)$ ，目標是接近 1。

7. 常見錯誤與排除 (Troubleshooting)

K-means 效果看起來很糟糕？

檢查資料是否為非球形（長條狀、弧形）。若是，請改用 DBSCAN。

再次確認你是否有做 `StandardScaler`。

會出現空群集 (Empty Clusters) 嗎？

別擔心，Scikit-learn 的實作很聰明。如果某個群集變空了，它會自動尋找離目前質心最遠的點，並強制將其指定為新質心。

維度災難 (Curse of Dimensionality)：

如果你有 100 個特徵，距離計算會變得毫無意義。實作建議：先用 PCA (主成分分析) 將資料壓縮到 2 或 3 維，再進行分群。這不僅能解決數學問題，還能讓你畫出散佈圖來視覺化驗證。

8. 動手練習與自我檢查表

動手練習題

觀念題：請比較「硬分群 (Hard Clustering)」與「軟分群 (Soft/Fuzzy Clustering)」的差異。

提示：K-means 屬於「硬分群」（每個人只能屬於一組，非 0 即 1）；而 Fuzzy C-means 屬於「軟分群」，它給出的是樣本屬於各組的機率（例如 85% 屬於 A 組，15% 屬於 B 組）。

實作題：請在 Colab 中調整 DBSCAN 的 `eps` 參數。觀察當半徑從小變大時，半月型資料的分群會如何從較多噪音點逐步形成兩個主要群集。

自我檢查表

- ☐ 我能解釋為什麼 K-means 需要預先設定 K 值。
- ☐ 我能說明為何「薪資」與「年齡」在分群前需要進行特徵縮放。
- ☐ 我能解讀樹狀圖 (Dendrogram) 並決定在哪裡「砍一刀」。
- ☐ 我能看懂輪廓圖，並指出哪些群集因為形狀太細長（刀片型）而代表品質不佳。

學習提醒：在聚類分析的世界裡，「沒有絕對正確的標準答案」。你的目標不是追求 100% 的準確（因為沒有標籤可以對），而是利用視覺化與評估指標（如輪廓係數）來說服利害關係人：為什麼這幾組客戶是有商業價值的。分群結果仍需配合領域知識、視覺化與評估指標解讀。下一章將介紹多層神經網路。