

第 17 章 | 生成對抗網路：從 GAN 到 DCGAN

學生版公開講義 | 請搭配本課程 Colab，依照段落逐步操作與自我檢查。

來源說明：課程參考《Python Machine Learning, 3rd Edition》；原始範例程式碼採 MIT License。本檔由恩恩統計家整理為學生版學習摘要，不含原書 PDF 或掃描內容。

1. 本章學習路線

生成對抗網路（Generative Adversarial Networks, GANs）使用生成器與判別器交替訓練，目標是產生接近訓練資料分佈的新樣本。本章從自動編碼器的壓縮表示開始，再實作 GAN 與 DCGAN 的訓練流程。

學習目標導引

完成本章後，你將掌握以下四大核心能力：

區分自動編碼器（Autoencoders）與生成模型之差異：理解 AE 的重建目標與生成模型的取樣目標有何差異。

理解生成器與判別器之間的對抗賽局邏輯：精確描述 G 與 D 之間的博弈演化過程。

掌握 GAN 損失函數的數學直覺：能解構 Minimax 函數 $V(D,G)$ 並理解飽和（Saturation）問題的解決方案。

具備實戰與調參能力：能在 Google Colab 環境下實作 DCGAN，並針對超參數進行穩健調整。

在我們進入兩軍對壘的 GAN 賽局之前，必須先打好地基。讓我們回顧一下資料壓縮的起點——「自動編碼器」。

2. 基礎奠基：從自動編碼器到生成模型

為什麼理解生成模型要先學壓縮？當我們將數千維的影像像素壓縮到極小的空間時，模型被迫丟棄雜訊，僅保留資料最本質的分佈特徵。理解這個「特徵提取」的過程，是學會生成資料分佈的前提。

概念白話說明

自動編碼器 (Autoencoder, AE)：這是一個對稱的結構，由「編碼器」與「解碼器」組成。你可以將其比喻為「精簡筆記製作」：編碼器將厚重的原始資料 x 濃縮成幾頁關鍵筆記（潛在向量 z ），解碼器則負責將筆記還原回原始內容 $x^{\wedge}$ 。

維度縮減與 PCA：當 AE 移除所有非線性激活函數時，其運作邏輯與主成分分析（PCA）幾乎相同。但 AE 的主要優勢在於非線性映射，這讓它能處理比 PCA 更複雜的資料結構。

關鍵對照表：Autoencoder 結構解析

類型	定義與特徵	實務意義
欠完備 (Undercomplete)	潛在空間維度 p 小於輸入維度 d ($p < d$)。	被迫學習資料的最精華特徵，常用於降維與去噪。
過完備 (Overcomplete)	潛在空間維度 p 大於輸入維度 d ($p > d$)。	若無特殊約束，模型會產生「平庸解」，僅是簡單背誦/複製輸入而無學習。
去噪 (Denoising AE)	在輸入加入隨機雜訊 ϵ ，要求模型還原出乾淨的 x 。	防止模型死背輸入！這強迫模型學習特徵間的相關性，大幅提高特徵提取的穩健性（Robustness）。

術語中英對照表

Latent Vector / 潛在向量：隱特徵表示，通常指瓶頸層的輸出 z 。

Bottleneck / 瓶頸層：網路中維度最低的關鍵層。

Dimensionality Reduction / 維度縮減：降低特徵維度以去除冗餘資訊。

雖然 AE 能還原影像，但它是「確定性」的——給它一樣的筆記，它永遠還原出一樣的結果。若要產生不同的新樣本，模型還需要可取樣的隨機輸入；下一節介紹 GAN。

3. 生成對抗網路 (GAN) 核心機制

GAN 包含生成器 (Generator) 與判別器 (Discriminator)：生成器產生樣本，判別器判斷樣本來自真實資料或生成模型。

核心觀念白話說明

生成器 (Generator, G)：目標是學習真實資料的分佈。它接收一個隨機向量 z ，試圖產出足以亂真的假幣。

判別器 (Discriminator, D)：目標是準確區分真偽。它對輸入給出機率評分，愈接近 1 代表愈相信是真實樣本。

賽局邏輯：這是一場「對抗賽 (Adversarial Game)」。 G 努力騙過 D ， D 則努力識破 G 。在動態競爭中，兩者的能力會同步提升。

損失函數深度解析

根據原始論文，GAN 遵循以下 Minimax 函數： $V(D,G)=E_{x \sim p_{data}(x)}[\log D(x)] + E_{z \sim p_z(z)}[\log(1-D(G(z)))]$

D 的策略：最大化此函數（讓真實樣本 $D(x)$ 趨近 1，生成樣本 $D(G(z))$ 趨近 0）。

G 的策略：最小化此函數（試圖讓 $D(G(z))$ 趨近 1）。

實際意義：飽和 (Saturation) 問題與策略轉換在訓練初期， G 生成的影像品質很差， D 能以極高信心 ($D(G(z)) \approx 0$) 識別。此時， $\log(1-D(G(z)))$ 的梯度幾近於零，導致 G 學習停滯，這就是「飽和現象」。解決方案：將 G 的目標從「最小化被識別的機率」改為「最大化被判為真實樣本的機率」。在程式碼實作中，將生成樣本的標籤翻轉為 1，並最大化 $\log(D(G(z)))$ 。

理論已備齊，接下來我們要將這場賽局搬到雲端實驗室。

4. 實戰環境：Google Colab 操作指南

GAN 訓練需要較多運算資源。若本機沒有可用 GPU，請依以下步驟設定 Google Colab，以縮短執行時間。

操作步驟清單

Runtime 設置：

在選單中點擊 Runtime -> Change runtime type。

在 Hardware accelerator 中務必選擇 GPU。

庫安裝與驗證：執行以下命令安裝 TensorFlow 2.0 並確認 GPU 已成功掛載：

Google Drive 掛載：為了避免訓練到一半連線中斷導致權重丟失，請掛載雲端硬碟進行備份：

環境就緒後，我們從結構最純粹的「Vanilla GAN」開始，看看全連接層如何處理影像。

5. 程式碼流程導讀：Vanilla GAN 實作

「Vanilla GAN」使用全連接層（Dense Layers）建構。在我們的學習範例中，將 z 維度設定為 20。

模型架構圖說

Generator (G)：將 20 維的 z 映射到 784 維（ 28×28 像素）。

中間層：使用 Leaky ReLU 以獲得全範圍的梯度，避免神經元死亡。

輸出層：使用 Tanh。這能讓輸出穩定在 $[-1, 1]$ 之間，是生成器學習的最佳實踐。

Discriminator (D)：將影像壓回 1 維的機率值。同樣使用 Leaky ReLU 並配合 Dropout (rate=0.5) 來強化泛化能力。

訓練循環 (Training Loop) 拆解

```
for epoch in range(num_epochs):
    for input_z, input_real in mnist_trainset:
        # Step 1: 更新判別器 (D)
        # 固定 G，計算 D(真實樣本) vs 1 與 D(生成樣本) vs 0 的 Binary Cross-Entropy

        # Step 2: 更新生成器 (G)
        # 固定 D，計算 D(生成樣本) vs 1 的損失（翻轉標籤，使 D 將生成樣本判為真實）
```

觀念重點：Vanilla GAN 將影像扁平化（Flatten）為一維向量，因此無法保留影像的「空間相關性」（Spatial Context）。雖然它能產生看起來像數字的圖案，但效果往往不夠細緻。

6. 進階強化：深度卷積 GAN (DCGAN) 與結構改良

為了克服 Vanilla GAN 的侷限，我們引入卷積神經網路（CNN）。DCGAN 是影像生成領域的關鍵標準架喚。

核心組件解析

轉置卷積 (Transposed Convolution)：這不是簡單的「解卷積（Deconvolution）」。它透過在輸入元素間插入零值進行「上採樣」，從而恢復影像維度。當 Stride 設定為 2 時，特徵圖的寬高將會翻倍。

批次歸一化 (Batch Normalization, BN)：

DCGAN 設計準則 (Design Rules)

實作 DCGAN 時，請遵循以下原則（參考 p.652）：

反向對稱原則：生成器（G）隨著層數增加，通道數（Filters）應減少但空間尺寸增加；判別器（D）則相反，通道數應增加但尺寸減少。

禁用 Bias：在 Batch Normalization 之前的卷積層，請設定 `use_bias=False`。因為 BN 的 β 參數已具備偏移功能，使用 Bias 反而冗餘。

激活函數配對：G 除了結尾用 Tanh，其餘一律用 Leaky ReLU；D 則全程使用 Leaky ReLU。

7. 動手練習、常見錯誤與自我檢查

常見錯誤與排除 (Troubleshooting)

實作時最常卡在以下兩點：

錯誤：生成的圖全是雜訊（Noise）。

排除：請檢查你的資料預處理。如果影像像素沒歸一化到 $[-1, 1]$ ，會與 Generator 的 Tanh 輸出範圍衝突，導致模型無法學習。

錯誤：Discriminator 損失降為 0。

排除：這是典型的 模式崩潰 (Mode Collapse) 前兆。如果 D 太早變得「太強」，G 的梯度會消失。請嘗試調低 D 的學習率，或簡化 D 的架構。

動手練習 (Workshop)

維度實驗：嘗試將 `z_size` 從 20 改為 100，觀察生成數字的細節是否更豐富？

分佈對比：將隨機向量從均勻分佈 (Uniform) 改為正態分佈 (Normal)，評估訓練初期的穩定性差異。

自我檢查清單

- ☐ 我是否理解將假樣本標籤設為 1 是為了解決 Saturation 梯度消失問題？
- ☐ 我能解釋為什麼 DCGAN 推薦在卷積層中不使用 Bias 嗎？
- ☐ 我清楚「轉置卷積」如何透過插入零值來實現影像放大的嗎？
- ☐ 我了解 Leaky ReLU 如何防止 GAN 訓練中常見的神經元死亡 (Dying ReLU) 嗎？

完成實作後，請比較生成器與判別器損失的變化，並檢查生成影像是否逐步穩定。